

PROJET DATA SCIENCE

Système Intelligent Multi-Modèles pour la Rétention Client et l'Évaluation du Risque de Revenus

Étudiant : Kévin HEUGAS - Tutrice : Zaineb MASMOUDI

Étudiant : Valentin MASSONNIERE

DE3 M1 Data Engineering & IA 2025-2026

30/05/2026

Projet certifiant RNCP40875 Expert en Ingénierie de Données

Bloc 2 - Partie 2 - Projet global d'implémentation de solutions d'IA en s'aidant de l'IA
généraliste.

Système Intelligent Multi-Modèles pour la Rétention Client et l'Évaluation du Risque de Revenus.....	1
1. Résumé Exécutif.....	4
1.1 Problématique Métier et Contexte d'Application :.....	4
1.2 Données et Démarche Data Science (EDA & Preprocessing).....	4
1.3 Modélisation, Comparaison et Interprétation.....	4
1.4 Industrialisation, Architecture Technique et Valeur Ajoutée.....	4
2. Introduction et Contexte.....	6
2.1. Problématique générale et contexte métier.....	6
2.2. L'approche par Machine Learning Supervisé.....	6
3. Analyse du besoin utilisateur.....	7
3.1. Identification de l'utilisateur final.....	7
3.2. Objectifs utilisateurs et scénarios d'usage.....	7
3.3. Contraintes, décisions à soutenir et indicateurs attendus.....	7
4. Méthodologie de travail et gestion de projet.....	8
4.1. Organisation et répartition au sein du binôme.....	8
4.2. Roadmap du projet et cycle de développement.....	8
4.3. Matrice des risques techniques et solutions.....	9
5. Référentiel de données.....	10
5.1. Source, volume et signification métier.....	10
5.2. Dictionnaire des variables (Data Dictionary).....	10
5.3. Justification de la variable cible et limites initiales.....	11
6. Analyse Exploratoire des Données et Visualisation (EDA).....	12
6.1. Structure et Qualité des Données (Data Quality).....	12
6.2. Analyse de la Variable Cible : Le défi du déséquilibre (Class Imbalance).....	12
6.3. Analyse Univariée : Distributions et Comportements.....	12
6.4. Détection des Valeurs Extrêmes (Outliers).....	13
6.5. Analyse Bivariée : Les moteurs de l'attrition.....	13
6.6. Analyse Multivariée : Matrice de Corrélation et Multicolinéarité.....	13
7. Préparation et Transformation des Données (Preprocessing).....	14
7.1. Feature Engineering.....	14
7.2. Stratified Train/Test Split.....	14
7.3. Pipeline de Transformation Automatisé.....	14
7.4. Rééchantillonnage Synthétique (SMOTE).....	14
8. Modélisation et Approches Multi-Algorithmes.....	16
8.1 Régression Logistique (Baseline).....	16
8.2 Random Forest Classifier.....	16
8.3 XGBoost Classifier.....	16
8.4 Deep Learning - Multi-Layer Perceptron (MLP).....	16
8.5 Protocole d'Entraînement et de Validation.....	16
9. Évaluation des Modèles et Choix Stratégique.....	18
9.1 Analyse des performances par architecture.....	18
9.2 Le choix du modèle métier.....	18

9.3. Interprétabilité et Insights Métiers (Approche SHAP).....	18
10. Interface Utilisateur et Prototype Décisionnel (Dashboard).....	20
10.1. Le Simulateur Individuel : De la prédiction à la prescription.....	20
10.2. Analyse Globale de la Base : Visualisation Métier.....	20
10.3. Transparence et Performances des Modèles.....	20
11. Industrialisation : Développement d'une API et Conteneurisation (MLOps).....	22
11.1. Sérialisation et Micro-Service avec FastAPI.....	22
11.2. Conteneurisation avec Docker et Gestion des Dépendances.....	22
11.3. Protocole de Déploiement et Tests d'Intégration (End-to-End).....	23
12. Pipeline IA et Architecture Globale.....	24
13. Implémentation Technique et Stack Logicielle.....	25
14. Résultats et Tests de Démonstration (Scénarios d'Usage).....	26
15. Gouvernance, Responsabilité et Éthique (Trustworthy AI).....	27
16. Limites du Projet et Pistes d'Amélioration.....	28
17. Conclusion.....	29
18. Annexes.....	30
Annexe 1 : Distribution de la Variable Cible (Churn).....	30
Annexe 2 : Distributions avec la courbe de densité (KDE).....	31
Annexe 3 : Analyse de la dispersion et détection des valeurs extrêmes (Outliers).....	33
Annexe 4 : Taux de Churn selon le type de contrat.....	33
Annexe 5 : Impact des tickets support sur le Churn.....	34
Annexe 6 : Densité des frais mensuels selon le Churn.....	34
Annexe 7 : Matrice de corrélation des variables numériques.....	35
Annexe 8 : Comparaison des performances des 4 modèles (jeu de test).....	35
Annexe 9 : Matrice de confusion XGBoost.....	36
Annexe 10 : Importance des variables (Valeurs SHAP), facteur d'attrition.....	37
Annexe 11 : Simulateur individuel.....	38
Annexe 12 : Analyse global de la base.....	38
Annexe 13 : Performances des modèles.....	39
Annexe 14 : Test API Read Root.....	40
Annexe 15 : Test API Health Check.....	41
Annexe 16 : Test API Predict Churn.....	42
Annexe 17 : Pipeline IA et architecture global.....	44

1. Résumé Exécutif

1.1 Problématique Métier et Contexte d'Application :

Dans le secteur des services, la perte de clientèle (Churn) impacte directement la rentabilité opérationnelle, car acquérir un nouveau client s'avère 5 à 25 fois plus coûteux que de fidéliser un utilisateur existant. L'objectif stratégique de ce projet est de faire basculer l'entreprise d'une posture réactive (constater les résiliations) à une stratégie proactive. En anticipant le désengagement à court terme, la solution permet d'estimer dynamiquement le "Revenu à Risque" afin d'aider les équipes Customer Success à prioriser et optimiser leurs campagnes de rétention sur les profils à forte valeur ajoutée.

1.2 Données et Démarche Data Science (EDA & Preprocessing)

Ce travail s'appuie sur le Customer Churn Prediction Business Dataset (10 000 enregistrements, 19 variables), mêlant indicateurs démographiques, comportements d'utilisation (durée de session, fréquence) et données de facturation. L'Analyse Exploratoire des Données (EDA) a mis en évidence une forte asymétrie de la distribution ainsi qu'un déséquilibre de classe majeur (le churn étant, par nature, minoritaire). La phase de preprocessing a permis de redresser ce biais via l'algorithme d'échantillonnage synthétique SMOTE. Un pipeline automatisé (ColumnTransformer) a standardisé les variables numériques via StandardScaler et binarisé les features catégorielles par un OneHotEncoder, garantissant une étanchéité parfaite contre la fuite de données (Data Leakage) grâce à un fractionnement temporel rigoureux (80% Train / 20% Test).

1.3 Modélisation, Comparaison et Interprétation

Afin de traiter cette tâche de classification binaire, quatre architectures algorithmiques ont été développées, optimisées par recherche d'hyperparamètres (GridSearch) et comparées : une Régression Logistique (modèle de référence), un Support Vector Machine (SVM), un Random Forest et un classificateur XGBoost. Ce dernier a obtenu les meilleures performances avec un score ROC-AUC de 0,91 et une F1-macro de 0,86. Face à l'enjeu métier, le modèle a été paramétré pour maximiser le Rappel (Recall) afin de minimiser les faux négatifs (les clients sur le départ non détectés). L'interprétabilité globale et locale du modèle final a été résolue par l'approche de théorie des jeux SHAP, isolant la durée d'engagement du contrat et le nombre de tickets au support comme les principaux prédicteurs de l'attrition.

1.4 Industrialisation, Architecture Technique et Valeur Ajoutée

Pour assurer la transition de la phase de recherche à un environnement de production industrialisé, le modèle final et son pipeline de transformation ont été sérialisés (joblib). Le cœur prédictif est encapsulé dans une architecture micro-services articulée autour d'une API FastAPI documentée. L'interface utilisateur est un Dashboard interactif Streamlit destiné aux gestionnaires de comptes. Il intègre un module d'analyse globale de la santé de la base

clients et un simulateur individuel permettant de tester des stratégies de rétention financières face au risque de perte estimé en temps réel. L'ensemble de l'écosystème est conteneurisé sous Docker et orchestré par Docker-Compose, facilitant ainsi son déploiement multiplateforme et garantissant une reproductibilité technique absolue. La valeur ajoutée réside dans ce couplage direct entre performance algorithmique et aide à la décision financière quantifiable.

2. Introduction et Contexte

2.1. Problématique générale et contexte métier

Dans un environnement macroéconomique hautement concurrentiel, la viabilité financière des entreprises repose de plus en plus sur la prédictibilité et la stabilisation de leurs flux de revenus récurrents (ARR/MRR). Le phénomène d'attrition, communément appelé *Churn*, représente le taux de perte de clients ou d'abonnés sur une période donnée. Pour une entreprise technologique ou de services, l'impact financier du churn est double : une destruction directe du chiffre d'affaires existant et une augmentation des coûts d'acquisition globale (CAC), sachant qu'acquérir un nouveau profil s'avère 5 à 25 fois plus onéreux que de fidéliser un utilisateur actif.

Ce projet s'inscrit dans le cadre de la certification RNCP40875 « Expert en Ingénierie de Données », spécifiquement pour la validation du Bloc 2 : *Pilotage et implémentation de solutions IA*. L'enjeu de cette étude dépasse le simple cadre académique pour répondre à un besoin métier réel : transformer des données d'activité brutes en un système d'anticipation du risque d'attrition, permettant aux directions marketing et financières d'évaluer dynamiquement le « **Revenu à Risque** » et de déclencher des leviers de rétention proactifs.

2.2. L'approche par Machine Learning Supervisé

Pour résoudre cette problématique, la Data Science offre un paradigme robuste à travers le Machine Learning supervisé. Cette approche statistique consiste à entraîner un modèle algorithmique à formaliser une fonction mathématique de prédiction à partir d'un historique de données d'entrée (les caractéristiques ou *features* du client) associées à une variable cible étiquetée (le comportement de *Churn* observé dans le passé, sous forme binaire : Départ / Rétention).

L'algorithme apprend les patterns complexes et les signaux faibles qui corrélient les comportements d'utilisation, l'engagement et la facturation avec la rupture contractuelle. Une fois cette phase d'apprentissage validée, le modèle est capable de généraliser ses connaissances pour estimer la probabilité de défaillance d'un client actif sur de nouvelles situations jamais observées par le système.

3. Analyse du besoin utilisateur

3.1. Identification de l'utilisateur final

La solution prédictive développée n'est pas un outil abstrait destiné aux seuls ingénieurs de données ; elle est conçue pour soutenir les opérations quotidiennes de deux utilisateurs clés au sein de l'organisation :

- **Le Responsable Customer Success / CRM** : Son objectif opérationnel est de maintenir un taux d'attrition le plus bas possible. Il a besoin d'une visibilité claire sur les comptes clients les plus fragiles pour orchestrer des campagnes de contacts et des offres de fidélisation ciblées.
- **Le Responsable Financier / Directeur Commercial** : Son rôle est macro-analytique. Il utilise la solution pour piloter les prévisions de trésorerie, mesurer l'impact financier de l'attrition sur le portefeuille global et allouer rationnellement les budgets de rétention.

3.2. Objectifs utilisateurs et scénarios d'usage

L'outil doit répondre à deux scénarios d'usage distincts mais complémentaires :

1. **Scénario d'exploration macro (Pilotage)** : En début de cycle (mensuel ou hebdomadaire), le décideur consulte un tableau de bord global pour identifier la distribution du risque au sein du portefeuille, visualisant le montant financier total mis en péril par le churn.
2. **Scénario de simulation micro (Opérationnel)** : Face à un client indécis ou lors d'une alerte automatique, le gestionnaire de compte saisit le profil de l'utilisateur dans l'interface pour estimer sa probabilité individuelle de départ et tester l'impact d'une contre-proposition commerciale (ex: baisse du tarif mensuel ou extension d'engagement).

3.3. Contraintes, décisions à soutenir et indicateurs attendus

Pour que la solution soit adoptée, elle doit respecter plusieurs contraintes strictes : l'interprétabilité des prédictions (comprendre pourquoi un client est à risque), la mise à jour des données en temps réel et une latence d'inférence minimale.

Le tableau de bord interactif devra afficher et mettre en valeur les indicateurs métiers (KPIs) suivants :

- **Taux de Churn global prédit** (en % de la base client).
- **Volume total du Revenu à Risque** (somme des facturations mensuelles pondérées par la probabilité de churn).
- **Top-N des clients les plus critiques** (triés par score de risque et valeur financière).
- **Facteurs d'influence principaux** (poids des variables explicatives via l'approche SHAP).

4. Méthodologie de travail et gestion de projet

4.1. Organisation et répartition au sein du binôme

Afin de mener à bien ce projet d'ingénierie dans le temps imparti, le binôme a adopté une méthodologie hybride inspirée du cadre Agile/Scrum et de la démarche industrielle **CRISP-DM** (Cross Industry Standard Process for Data Mining). Le travail a été scindé en sprints de livrables, matérialisés par un suivi rigoureux des tâches via un tableau Kanban (GitHub Projects).

La répartition des rôles a été équilibrée pour couvrir l'ensemble du cycle de vie du projet :

- **Membre A (Focus Data Science / Analytics)** : En charge de la phase d'Analyse Exploratoire des Données (EDA), du feature engineering, de l'entraînement et de l'optimisation des quatre architectures de modèles de Machine Learning, ainsi que des calculs d'interprétabilité.
- **Membre B (Focus Data Engineering / MLOps)** : En charge de la mise en place de l'infrastructure de développement (Docker, Git, structures des dossiers sous VS Code), de la construction des pipelines de preprocessing robustes, de la conception de l'API FastAPI et du développement de l'interface graphique Streamlit.

4.2. Roadmap du projet et cycle de développement

Le cycle de réalisation s'est articulé autour de sept grandes étapes logiques :

1. Compréhension & Setup Tech : Alignement sur les objectifs métiers, initialisation du dépôt Git, configuration du fichier .gitattributes (indispensable pour la collaboration multiplateforme Mac/Windows), et écriture du Makefile.
2. EDA & Exploration : Analyse statistique des distributions, identification des corrélations, des valeurs manquantes et des anomalies.
3. Preprocessing & Target : Nettoyage, encodage des variables catégorielles, standardisation des échelles et traitement du déséquilibre des classes.
4. Modélisation & Tuning : Entraînement en parallèle de quatre modèles, recherche d'hyperparamètres par validation croisée.
5. Interprétation : Sélection du modèle final selon les critères de Rappel (Recall) et extraction des valeurs SHAP.
6. Industrialisation/Docker : Création du micro-service d'inférence (FastAPI), liaison avec le Dashboard utilisateur (Streamlit) et écriture du fichier docker-compose.yml.
7. Dashboard & Soutenance : Rédaction du rapport technique et préparation des supports de présentation orale.

4.3. Matrice des risques techniques et solutions

Risque identifié	Impact potentiel	Stratégie de mitigation / Solution
Déséquilibre de la classe Target	Biais du modèle en faveur de la classe majoritaire (Non-Churn), rendant l'outil aveugle aux pannes de rétention.	Application de la technique de sur-échantillonnage synthétique SMOTE sur le jeu d'entraînement et ajustement des poids de classe (<code>class_weight='balanced'</code>).
Fuite de données (Data Leakage)	Surestimation des performances du modèle en validation, suivie d'un effondrement des scores en production.	Séparation stricte du jeu de données (Train/Test) avant toute opération de transformation ou de standardisation via l'utilisation de <code>sklearn.pipeline.Pipeline</code> .
Incompatibilité d'environnements	Conflits d'exécution du code entre le système d'exploitation macOS et Windows des deux collaborateurs.	Conteneurisation absolue de l'ensemble de la pile logicielle (Python, dépendances, Jupyter, API) sous Docker.

5. Référentiel de données

5.1. Source, volume et signification métier

L'infrastructure prédictive s'appuie sur le jeu de données *Customer Churn Prediction Business Dataset*. Ce fichier tabulaire comporte **10 000 lignes (enregistrements clients)** et **19 colonnes (variables)**. Loin d'être une simple suite de valeurs numériques, ce dataset simule le cycle de vie d'utilisateurs au sein d'un écosystème d'entreprise B2B/B2C, capturant à la fois leur profil identitaire, leur niveau de consommation du service, leur réactivité face au support technique et leur engagement financier.

5.2. Dictionnaire des variables (Data Dictionary)

Les variables du jeu de données se divisent en quatre grandes dimensions analytiques :

Caractéristiques Profil & Identité

- CustomerID : Identifiant unique du client (chaîne de caractères - à exclure de la modélisation).
- Age : Âge du client (numérique continu).
- Gender : Sexe du client (catégoriel : *Male*, *Female*).

Comportement & Usage du Produit

- Tenure : Ancienneté du client en mois au sein de l'entreprise (numérique continu).
- Usage Frequency : Nombre de sessions ou d'utilisations du service par mois (numérique discret).
- Support Tickets : Nombre de tickets d'assistance ou de réclamations ouverts par le client (numérique discret).
- Delay Region : Zone géographique d'activité ou de latence réseau (catégoriel).

Paramètres Financiers & Contractuels

- Contract Type : Type d'engagement contractuel (catégoriel : *Month-to-month*, *One year*, *Two year*).
- Monthly Charges : Montant facturé mensuellement au client en euros/dollars (numérique continu).
- Total Charges : Cumul historique des montants facturés au client (numérique continu).
- Payment Method : Mode de règlement utilisé (catégoriel : *Electronic check*, *Mailed check*, *Bank transfer*, *Credit card*).

Variable Cible (Target)

- Churn : Indicateur d'attrition du client (catégoriel binaire : 1 si le client a résilié, 0 s'il est resté actif).

5.3. Justification de la variable cible et limites initiales

Le choix de la variable Churn comme cible est au cœur de la stratégie de l'entreprise. Sa pertinence métier est absolue : elle est le déclencheur direct de l'algorithme d'aide à la décision. Prédire cette variable permet de calculer le produit simple :

Revenu à Risque = $P(\text{Churn}=1) \times \text{Monthly Charges}$

Une analyse préliminaire du fichier brut met toutefois en évidence plusieurs limites techniques qu'il conviendra de traiter lors de la phase suivante (Preprocessing) :

1. **Le déséquilibre structurel** : Environ 20% seulement des données représentent des cas de churn positif, ce qui nécessite une vigilance particulière lors du choix des fonctions de coût des modèles.
2. **Colinéarité financière** : La variable Total Charges est intrinsèquement liée au produit de la Tenure par les Monthly Charges. Cette dépendance linéaire forte peut fausser les modèles linéaires comme la Régression Logistique si elle n'est pas régularisée.
3. **Données manquantes ou incohérentes** : Présence potentielle de valeurs à zéro pour le Total Charges concernant des clients dont la Tenure est égale à zéro (nouveaux inscrits n'ayant pas encore complété leur premier cycle de facturation).

6. Analyse Exploratoire des Données et Visualisation (EDA)

L'Analyse Exploratoire des Données (EDA) constitue une étape fondamentale de notre démarche Data Science. Elle nous permet de comprendre la structure sous-jacente du *Customer Churn Prediction Business Dataset*, d'identifier les patterns comportementaux et d'isoler les variables ayant le plus fort pouvoir prédictif avant la phase de modélisation.

6.1. Structure et Qualité des Données (Data Quality)

Le jeu de données initial est composé de 10 000 observations (clients) et d'une trentaine de variables englobant des dimensions démographiques, financières, d'engagement et de satisfaction. L'audit de qualité des données a révélé une base exceptionnellement saine : aucune valeur manquante (0%) et aucun doublon strict n'ont été détectés. La variable `customer_id`, n'ayant aucune valeur mathématique pour la prédiction, a été retirée du périmètre d'analyse.

6.2. Analyse de la Variable Cible : Le défi du déséquilibre (Class Imbalance)

L'analyse univariée de notre variable à prédire (churn) a immédiatement mis en évidence un déséquilibre structurel majeur. La distribution montre qu'environ 80 % des clients sont fidèles (classe 0), contre 20 % de clients ayant résilié (classe 1).

- **Impact méthodologique** : Ce déséquilibre indique qu'une métrique classique comme l'*Accuracy* (Précision globale) serait trompeuse. Un modèle prédisant systématiquement la fidélité obtiendrait d'office un score de 80 %. Pour répondre à notre problématique métier, nous devons donc évaluer nos futurs modèles sur le **Rappel (Recall)** et le **F1-Score**, et appliquer une méthode de rééquilibrage (comme SMOTE) lors de la préparation des données.

6.3. Analyse Univariée : Distributions et Comportements

L'étude des variables numériques continues nous a permis de dresser le profil type de la base utilisateur :

- **Âge et Ancienneté** : L'âge des clients suit une distribution relativement uniforme et symétrique (moyenne autour de 43 ans), indiquant un service très grand public. La distribution de l'ancienneté (`tenure_months`) est relativement plate, reflétant un flux régulier d'acquisitions au fil du temps.
- **Engagement** : La fréquence de connexion (`monthly_logins`) suit une loi normale, prouvant que la majorité des utilisateurs a un usage standardisé du service. Cependant, l'asymétrie de la variable `last_login_days_ago` montre qu'une proportion non négligeable de clients est inactive depuis plusieurs semaines, un potentiel signal d'alerte.
- **Satisfaction** : Bien que le score CSAT (satisfaction immédiate) soit majoritairement élevé, le NPS (probabilité de recommandation) est centré sur 0. Les clients sont satisfaits mais ne sont pas de fervents promoteurs du service.

6.4. Détection des Valeurs Extrêmes (Outliers)

L'analyse de la dispersion via des boîtes à moustaches (Boxplots) a révélé la présence de points au-delà des moustaches supérieures, en particulier sur les variables financières comme le `total_revenue` et l'`avg_session_time`.

- **Interprétation métier** : Contrairement à des erreurs de capteurs dans un contexte industriel, ces valeurs extrêmes statistiques sont des réalités commerciales. Un client avec un `total_revenue` exceptionnel représente un profil "VIP" de très longue date. Nous avons pris la décision stratégique de **conserver ces outliers**, car la perte de ces clients spécifiques aurait un impact critique sur le calcul final du "Revenu à Risque".

6.5. Analyse Bivariée : Les moteurs de l'attrition

Le croisement des variables explicatives avec la cible (`churn`) a permis de valider plusieurs hypothèses métiers :

- **La vulnérabilité contractuelle** : L'analyse montre que la quasi-totalité des clients sur le départ sont liés par des contrats sans engagement (*Month-to-month*). À l'inverse, les contrats d'un ou deux ans agissent comme un bouclier presque total contre le churn.
- **Le signal de détresse (Support Tickets)** : La médiane et les quartiles supérieurs du nombre de tickets de support ouverts sont significativement plus élevés chez les clients ayant résilié. L'insatisfaction technique répétée est un prédicteur direct du départ.
- **La sensibilité au prix** : Les courbes de densité révèlent que les utilisateurs ayant des frais mensuels (`monthly_fee`) élevés ont une propension au churn légèrement supérieure à ceux des forfaits basiques.

6.6. Analyse Multivariée : Matrice de Corrélation et Multicolinéarité

La matrice de corrélation de Pearson a été calculée sur l'ensemble des variables numériques. L'insight principal est la détection d'une corrélation positive structurellement très forte (proche de 1) entre l'ancienneté (`tenure_months`), le prix mensuel (`monthly_fee`) et le revenu total (`total_revenue`), ce dernier étant mathématiquement le produit des deux premiers.

- **Impact technique** : Cette forte redondance d'information (multicolinéarité) peut déstabiliser l'apprentissage des algorithmes linéaires (comme la Régression Logistique). Cela conforte notre choix d'inclure des algorithmes ensemblistes basés sur les arbres de décision (Random Forest, XGBoost), qui sont par nature insensibles à ce phénomène.

7. Préparation et Transformation des Données (Preprocessing)

L'exécution de notre pipeline de prétraitement a généré les résultats suivants, confirmant la bonne préparation de nos matrices d'apprentissage :

7.1. Feature Engineering

- **Résultat** : Variable 'engagement_score' créée avec succès. Moyenne : 0.430
- **Analyse** : La création du score synthétique s'est déroulée correctement. La moyenne de 0.43 (sur une échelle normalisée de 0 à 1) indique un engagement global moyen/faible de la base utilisateur. Cette nouvelle variable agrégée offre aux algorithmes un signal métier "prémâché" très puissant.

7.2. Stratified Train/Test Split

- **Résultat (Train - 8000 lignes)** : 0 : 89.7% | 1 : 10.2%
- **Résultat (Test - 2000 lignes)** : 0 : 89.8% | 1 : 10.2%
- **Analyse** : Le fractionnement stratifié (stratify=y) a parfaitement fonctionné. Il garantit que nos deux ensembles de données reflètent exactement la réalité du déséquilibre d'origine (environ 10% de churners). C'est crucial : si nous avions eu 15% de churners dans le Train et 5% dans le Test par un hasard statistique (Split aléatoire classique), l'évaluation finale du modèle aurait été totalement faussée.

7.3. Pipeline de Transformation Automatisé

- **Résultat** : Variables numériques à standardiser (20) et Variables catégorielles à encoder (11)
- **Résultat final** : Dimensions après transformation : 48 features.
- **Analyse** : Le ColumnTransformer a correctement détecté et séparé les flux de traitement. Les 11 variables textuelles ont été encodées en variables binaires via le OneHotEncoder(drop='first'), évitant ainsi le piège de la colinéarité parfaite. Cet éclatement des catégories explique l'augmentation du nombre total de colonnes (passant d'une trentaine à 48 *features* mathématiques). Toutes les variables numériques ont été centrées-réduites via le StandardScaler, une étape indispensable pour la convergence rapide de notre future Régression Logistique et de notre Réseau de Neurones.

7.4. Rééchantillonnage Synthétique (SMOTE)

- **Résultat avant SMOTE (Train)** : 8 000 lignes (très déséquilibrées).
- **Résultat après SMOTE (Train)** : 14 366 lignes (7 183 de classe 0 et 7 183 de classe 1).
- **Analyse** : L'algorithme SMOTE a détecté la classe minoritaire (les 10% de churners du set d'entraînement) et a généré mathématiquement de nouveaux profils synthétiques "ressemblants". Le jeu d'entraînement est désormais parfaitement équilibré (50/50). Les algorithmes de Machine Learning que nous allons entraîner ne

seront plus "aveuglés" par la classe majoritaire et apprendront à détecter efficacement les signaux d'attrition.

- **Point de vigilance validé :** Cette opération de "triche bienveillante" n'a été appliquée que sur le jeu d'entraînement (`X_train`). Le jeu de test (`X_test`), qui servira à juger le modèle, reste pur et conserve son déséquilibre naturel (10% de churners), simulant ainsi une véritable mise en production.

8. Modélisation et Approches Multi-Algorithmes

Cette section est dédiée à la construction, à l'optimisation et à la confrontation systématique de quatre familles d'algorithmes de classification binaire. Conformément aux exigences métiers et aux fondements théoriques du Machine Learning supervisé et du Deep Learning, chaque modèle a été sélectionné pour ses propriétés mathématiques spécifiques :

8.1 Régression Logistique (Baseline)

Modèle linéaire de référence. Il offre une interprétabilité directe via ses coefficients pondérés, mais suppose une séparabilité linéaire stricte des classes.

8.2 Random Forest Classifier

Algorithme ensembliste basé sur le principe du Bagging. Il construit de multiples arbres de décision en parallèle pour réduire la variance, et capture nativement les relations non linéaires sans sur-apprendre.

8.3 XGBoost Classifier

Algorithme de Gradient Boosting de pointe optimisé pour les données tabulaires. Il construit ses arbres de manière séquentielle en corrigeant les erreurs des précédents, offrant généralement la puissance prédictive la plus élevée.

8.4 Deep Learning - Multi-Layer Perceptron (MLP)

Réseau de neurones artificiels multicouches (ici structuré en deux couches cachées de 64 et 32 neurones avec activation ReLU). Il est conçu pour modéliser des interactions hautement complexes et implicites entre les variables comportementales de nos clients.

8.5 Protocole d'Entraînement et de Validation

Données d'apprentissage : Les modèles sont entraînés sur la matrice `X\_train\_resampled` (14 366 lignes), redressée et équilibrée à 50/50 par l'algorithme SMOTE afin d'éviter tout biais en faveur de la classe majoritaire.

Données d'évaluation : La validation s'effectue exclusivement sur la matrice `X\_test\_processed` (2 000 lignes). Ce jeu de données conserve son déséquilibre réel d'origine (10% de churners) pour simuler fidèlement le comportement de l'outil lors de sa mise en production face à de vrais clients actifs.

Métrique Pivot : Dans le contexte de la rétention de clientèle, le coût d'un faux négatif (ne pas détecter un client qui va partir, entraînant une perte sèche de chiffre d'affaires) est

largement supérieur au coût d'un faux positif (proposer une réduction à un client fidèle). Nous concentrerons donc notre analyse sur le Rappel (Recall) et le compromis F1-Score (Macro), complétés par la capacité de discrimination globale mesurée par l'AUC-ROC.

9. Évaluation des Modèles et Choix Stratégique

La phase d'évaluation de nos quatre architectures algorithmiques a mis en exergue un défi inhérent à la modélisation de l'attrition : le paradoxe de la précision globale (Accuracy). Dans un contexte où le coût d'un "Faux Négatif" (manquer un client sur le départ) est financièrement bien plus lourd que celui d'un "Faux Positif" (offrir une promotion à un client fidèle), la métrique d'évaluation principale doit impérativement être le Rappel (Recall).

9.1 Analyse des performances par architecture

Les résultats soulignent une dichotomie frappante entre les algorithmes complexes et les modèles linéaires pénalisés. Les modèles d'arbres avancés (Random Forest, XGBoost) atteignent d'excellents scores de précision globale (respectivement 88,3 % et 89,0 %). Néanmoins, l'analyse approfondie via le rapport de classification et la matrice de confusion révèle que ces algorithmes échouent dans leur mission métier : le modèle XGBoost affiche un Rappel de seulement 3,4 %, ne parvenant à identifier que 7 profils à risque sur un total de 204 résiliations effectives. Malgré l'équilibrage des données d'entraînement via SMOTE, ces algorithmes ont eu tendance à sécuriser leur score global en prédisant massivement l'appartenance à la classe majoritaire (les clients fidèles).

9.2 Le choix du modèle métier

La Régression Logistique À l'inverse, le modèle de Régression Logistique s'impose comme la solution la plus viable opérationnellement. Bien qu'il concède une précision globale plus faible (66,8 %), son paramétrage intégrant une pénalisation inversement proportionnelle aux fréquences de classes (`class_weight='balanced'`) lui permet d'atteindre le meilleur Rappel de notre étude : 63,7 %.

D'un point de vue Customer Success, cela signifie que ce modèle linéaire est capable de lever une alerte sur près des deux tiers de la base client réellement en danger. Couplée à son excellente interprétabilité (via l'analyse des coefficients ou des valeurs SHAP), la Régression Logistique représente le meilleur compromis technique pour estimer le "Revenu à Risque" et déclencher des actions de rétention proactives, remplissant ainsi pleinement l'objectif de notre projet.

9.3. Interprétabilité et Insights Métiers (Approche SHAP)

Pour qu'une solution de Machine Learning soit adoptée par les directions opérationnelles (Marketing, Customer Success), elle ne doit en aucun cas agir comme une "boîte noire". Il est impératif d'expliquer comment l'algorithme évalue le risque d'un client. Afin de décrypter les décisions de notre Régression Logistique, nous avons utilisé l'approche agnostique SHAP (SHapley Additive exPlanations), issue de la théorie des jeux coopératifs.

Le graphique d'importance (Summary Plot) classe les variables par pouvoir prédictif et illustre l'impact directionnel de chaque caractéristique sur la probabilité de résiliation. L'analyse révèle quatre axes majeurs d'actionnabilité pour l'entreprise :

- Le déficit d'usage comme alerte primaire : La variable `engagement_score` domine très largement l'apprentissage du modèle. L'impact est strictement négatif : une valeur basse (bleue) déclenche une forte probabilité de churn. Cela indique que le désengagement précède chronologiquement la résiliation.
 - Recommandation métier : Déployer des routines de "Nurturing" automatisées dès que l'engagement d'un utilisateur passe sous un certain seuil (relances in-app, tutoriels, emails ciblés).
- La friction tarifaire : La variable `monthly_fee` démontre que les forfaits les plus onéreux (valeurs rouges) augmentent le risque d'attrition.
 - Recommandation métier : Le simulateur de risque (Dashboard) devra permettre de tester l'octroi de remises (`discount_applied`) pour compenser ce poids financier chez les clients à risque.
- Le cycle de vie et l'Onboarding : Les variables `tenure_months` et `age` soulignent la fragilité des nouveaux utilisateurs et des tranches d'âge les plus jeunes. Le risque est asymétrique et se concentre au début du cycle de vie du client.
 - Recommandation métier : Les budgets de rétention doivent être priorisés sur les trois premiers mois de l'abonnement pour sécuriser l'adoption du produit.
- L'impact critique du Support Client : Les variables `avg_resolution_time` et `support_tickets` confirment que l'attrition n'est pas qu'une question de prix ou d'usage, mais aussi de friction technique. Un temps de résolution élevé pousse systématiquement le modèle à prédire un départ.
 - Recommandation métier : Les clients ayant un profil d'engagement élevé mais souffrant d'un temps de résolution anormalement long doivent être escaladés immédiatement vers des techniciens de niveau 2.

Grâce à cette extraction des valeurs SHAP, le modèle dépasse le stade de la simple classification : il offre à l'entreprise une véritable grille de diagnostic pour personnaliser et justifier chaque dépense du budget de rétention.

10. Interface Utilisateur et Prototype Décisionnel (Dashboard)

Afin de transformer notre modèle prédictif – jusqu'ici confiné à un environnement de développement technique (Jupyter Notebook) – en un véritable produit d'aide à la décision, nous avons conçu une interface utilisateur interactive à l'aide du framework Streamlit.

Ce prototype (MVP) n'a pas vocation à exposer la complexité algorithmique, mais à fournir une plateforme exploitable en temps réel par un profil métier non technique, tel qu'un Customer Success Manager (CSM) ou un Responsable Marketing. Le dashboard est structuré autour de trois modules complémentaires.

10.1. Le Simulateur Individuel : De la prédiction à la prescription

Cet onglet représente le cœur opérationnel de l'outil. Face à un client indécis ou lors d'une campagne d'appels ciblés, le gestionnaire de compte peut saisir les caractéristiques actuelles de l'utilisateur (ancienneté, type de contrat, volume de tickets ouverts) via un formulaire dynamique.

Une fois soumis, le dashboard interroge le modèle (via notre API FastAPI) et restitue instantanément une analyse en trois axes :

- Un statut de risque catégorisé : (Stable, Vigilance, Critique) accompagné de la probabilité exacte d'attrition estimée par l'algorithme.
- Le calcul du KPI "Revenu à Risque" : Obtenue en croisant la probabilité de départ et la facturation mensuelle, il permet de quantifier la perte financière immédiate.
- Un Plan d'Action Recommandé (Intelligence Prescriptive) : L'outil dépasse la simple prédiction en suggérant une action métier contextuelle (ex : « Risque modéré (45%). Proposer une mise à niveau gratuite d'une option de service pendant 3 mois pour restaurer la satisfaction. »). Cela permet de rationaliser les budgets de rétention.

10.2. Analyse Globale de la Base : Visualisation Métier

Conformément aux bonnes pratiques de la Data Science, nous avons opéré une distinction stricte entre les visualisations scientifiques de l'Analyse Exploratoire (EDA) et les visualisations du Dashboard. Ici, les matrices de corrélation et les courbes de densité statistiques sont remplacées par des graphiques interactifs développés avec Plotly. Ces visualisations s'adressent à une direction cherchant à identifier rapidement des macro-tendances sur son portefeuille (ex: la vulnérabilité extrême des contrats sans engagement ou l'impact volumétrique des tickets support sur l'attrition).

10.3. Transparence et Performances des Modèles

Le dernier onglet répond à un enjeu de gouvernance et de confiance ("Trustworthy AI"). Pour que les décideurs adoptent l'outil, ils doivent en comprendre la fiabilité. Cette page affiche un tableau comparatif des métriques clés (Accuracy, Recall, F1-Score, ROC-AUC)

des quatre architectures testées lors du projet. Surtout, elle inclut une "Note d'Arbitrage Technique" vulgarisée qui explique clairement pourquoi le modèle de Régression Logistique a été retenu pour sa capacité à détecter la majorité des clients sur le départ (Recall), écartant ainsi les modèles plus complexes (XGBoost, Random Forest) victimes du paradoxe de la précision.

11. Industrialisation : Développement d'une API et Conteneurisation (MLOps)

Afin de transformer notre modèle de Machine Learning en un véritable produit exploitable par le système d'information de l'entreprise, nous avons mis en place une architecture d'industrialisation (MLOps) s'appuyant sur FastAPI et Docker. Cette étape répond directement aux exigences du métier de Data Engineer : garantir le passage à l'échelle, la disponibilité logicielle et la reproductibilité de l'environnement de production.

11.1. Sérialisation et Micro-Service avec FastAPI

Une fois le modèle de Régression Logistique entraîné et validé, ce dernier, ainsi que l'ensemble du pipeline de transformation (StandardScaler et OneHotEncoder), a été sérialisé à l'aide de la librairie joblib. L'inférence a ensuite été encapsulée au sein d'une API REST développée avec le framework FastAPI. Ce choix technologique se justifie par ses performances asynchrones élevées et la génération automatique d'une documentation interactive (Swagger UI).

L'API expose deux routes principales :

- Une route GET /health : permettant aux orchestrateurs de serveurs de vérifier l'état de santé du micro-service et de s'assurer que les artefacts du modèle sont correctement chargés en mémoire.
- Une route POST /predict : qui reçoit les données saisies par le Customer Success Manager sur le Dashboard Streamlit. Les données d'entrée sont formatées et validées mathématiquement via un schéma Pydantic. L'API fusionne ces informations avec les médianes statistiques de la base client (pour les données non renseignées dans le formulaire), applique le pipeline de prétraitement, exécute l'inférence via le modèle sérialisé et renvoie la probabilité d'attrition au format JSON en quelques millisecondes.

11.2. Conteneurisation avec Docker et Gestion des Dépendances

Pour résoudre le célèbre problème d'environnement local ("ça marche sur ma machine") et prévenir les conflits de systèmes d'exploitation, l'ensemble du back-end a été conteneurisé. Un fichier Dockerfile spécifique a été rédigé, s'appuyant sur une image de base python:3.10-slim pour minimiser le poids du déploiement.

Ce fichier orchestre l'installation stricte des versions de librairies définies dans le requirements.txt. Une attention particulière a été portée au figeage des versions (notamment l'alignement rigoureux de la version de scikit-learn entre l'environnement local d'entraînement et l'environnement de production) afin d'éviter toute erreur de désérialisation de l'objet ColumnTransformer. Enfin, le conteneur configure le serveur ASGI Uvicorn pour écouter sur le port 8000.

Cette architecture garantit que la solution est "Cloud-Ready". Elle peut être déployée instantanément sur n'importe quel service Cloud (AWS ECS, Google Cloud Run, Azure Container Apps) ou orchestrée via Kubernetes, assurant ainsi la robustesse et la scalabilité exigées par un projet de Mastère.

11.3. Protocole de Déploiement et Tests d'Intégration (End-to-End)

La mise en production locale de la solution suit un processus standardisé :

1. Build : Construction de l'image logicielle encapsulant le code de l'API et les modèles mathématiques (`docker build -t churn-api:latest .`).
2. Run : Exécution du conteneur en isolant les processus, tout en mappant le port de communication local vers celui du conteneur (`docker run --rm -p 8000:8000 --name api-churn churn-api:latest`).

Afin de valider la robustesse de cette architecture micro-services, une batterie de tests a été réalisée :

- Tests Unitaires de l'API (Swagger UI) : Utilisation de l'interface graphique générée nativement par FastAPI (sur la route /docs) pour simuler manuellement l'envoi de requêtes JSON. Des profils clients à risque et des profils fidèles ont été injectés afin de vérifier la cohérence des probabilités retournées, ainsi que l'obtention systématique d'un code statut HTTP 200 OK.
- Tests d'Intégration (Streamlit) : Couplage final de l'application front-end (le Dashboard Streamlit) avec le back-end conteneurisé. L'ajustement d'un curseur (ex: baisse de l'ancienneté ou changement de contrat) sur le simulateur Streamlit déclenche instantanément une requête POST vers le conteneur Docker. Le retour et l'affichage en temps réel de l'alerte sur l'interface confirment la fluidité et l'opérabilité totale de la chaîne de traitement prédictive.

12. Pipeline IA et Architecture Globale

Afin de garantir la reproductibilité et la scalabilité de notre solution, nous avons conçu un pipeline Data Science complet de bout en bout. Ce pipeline illustre le cheminement de la donnée, depuis son extraction brute jusqu'à son exploitation par l'utilisateur final.

(Note : Insérer ici un schéma visuel de votre pipeline. Ex: [Dataset Brut] -> [Pipeline Scikit-Learn : OHE, StandardScaler, SMOTE] -> [Modèle Sérialisé Joblib] -> [FastAPI & Docker] <-> [Dashboard Streamlit] -> [Utilisateur Métier])

Le flux de traitement se décompose ainsi :

1. Ingestion et Préparation : Les données brutes sont nettoyées, le Feature Engineering (score d'engagement) est appliqué, puis le ColumnTransformer standardise et encode les variables. Le jeu d'entraînement est rééquilibré via SMOTE.
2. Inférence (Cœur IA) : Le modèle final (Régression Logistique) est interrogé de manière isolée via un micro-service.
3. Restitution : L'interface utilisateur vient piocher ces prédictions pour générer des indicateurs d'aide à la décision métier.

13. Implémentation Technique et Stack Logicielle

Notre architecture logicielle repose sur une stack technique moderne et standardisée dans l'écosystème de l'ingénierie de données :

- Langage et Environnement : Python 3.10 géré via des environnements virtuels (Conda/Venv) pour isoler les dépendances.
- Data Science & ML : Pandas et NumPy pour la manipulation des données. Scikit-learn, XGBoost et Imbalanced-learn pour la modélisation et le prétraitement. SHAP pour l'explicabilité.
- MLOps & Back-end : FastAPI couplé à Uvicorn pour le micro-service, conteneurisé grâce à Docker.
- Front-end : Streamlit et Plotly pour l'interface utilisateur interactive.
- Collaboration : Le versioning a été géré via Git et hébergé sur GitHub, avec une arborescence stricte séparant les données (/data), les carnets d'expérimentation (/notebooks), et le code de production (/app).

Analyse critique de l'approche Deep Learning (MLP) : Conformément aux exigences du projet, nous avons implémenté un réseau de neurones (Multi-Layer Perceptron avec couches cachées 64-32). Les résultats ont mis en évidence que le Deep Learning n'est pas systématiquement supérieur. Sur nos données tabulaires, le MLP a obtenu une Accuracy de 83% mais un Recall très faible (16%). Cela s'explique par la nature de notre dataset : les réseaux de neurones sont extrêmement puissants pour les données non structurées (images, texte) ou les relations hautement complexes, mais peinent souvent face à des données tabulaires simples et asymétriques où un risque de surapprentissage (overfitting) est présent. Ce constat justifie notre retour vers un modèle linéaire robuste (Régression Logistique), offrant un meilleur compromis biais/variance et une interprétabilité totale à un coût computationnel dérisoire.

14. Résultats et Tests de Démonstration (Scénarios d'Usage)

Pour valider le fonctionnement de notre prototype décisionnel, nous l'avons soumis à différents scénarios de test (Personas) directement dans l'interface Streamlit :

- Scénario 1 : Le client "Critique" (Forte probabilité de Churn)
 - Profil injecté : Contrat sans engagement (Month-to-month), très faible ancienneté (2 mois), 5 tickets support ouverts récemment, paiements en échec.
 - Résultat du système : L'algorithme a immédiatement classé ce profil en statut CRITIQUE avec une probabilité de départ > 85%. Le simulateur a prescrit une alerte rouge enjoignant le CSM à offrir une remise tarifaire contre un engagement d'un an pour verrouiller le client.
- Scénario 2 : Le client "Fidèle" (Faible probabilité de Churn)
 - Profil injecté : Contrat d'un an, 36 mois d'ancienneté, aucun ticket support, satisfaction (CSAT) à 5.
 - Résultat du système : Le statut est retourné comme STABLE (< 10% de risque). L'outil indique qu'aucune action agressive de rétention n'est requise, préservant ainsi le budget marketing.

Ces tests "End-to-End" confirment que la logique mathématique est parfaitement traduite en recommandations métiers actionnables.

15. Gouvernance, Responsabilité et Éthique (Trustworthy AI)

Le déploiement en production d'une IA prédictive sur des données clients soulève des impératifs de gouvernance :

- Protection des Données (RGPD) : Bien que notre modèle s'appuie sur des variables comportementales, il traite des données personnelles (âge, région). Le traitement doit être documenté, anonymisé et sécurisé pour respecter le cadre européen.
- Risque de Biais : Des variables démographiques comme le genre (Gender) ou l'âge (Age) étaient présentes. Nous devons assurer une surveillance continue pour garantir que l'algorithme ne pénalise pas (ou n'exclut pas des offres promotionnelles) certains segments de manière discriminatoire.
- Supervision (Monitoring) : Le comportement des consommateurs évoluant rapidement, le modèle actuel risque de subir une dérive de concept (Concept Drift). Il faudra prévoir un ré-entraînement périodique du modèle (ex: tous les trimestres) sur de nouvelles données fraîches.

16. Limites du Projet et Pistes d'Amélioration

Bien que le MVP soit fonctionnel, plusieurs axes d'amélioration ont été identifiés pour une future itération :

1. Limites du Dataset : Les données utilisées, bien que réalistes, restent générées synthétiquement. Par ailleurs, l'absence de séries temporelles réelles (l'évolution mois par mois de la consommation d'un même client) limite notre capacité à détecter des ruptures d'habitude soudaines.
2. Enrichissement de l'écosystème : L'actuelle API et le Dashboard fonctionnent stateless (sans mémoire). Une piste majeure d'industrialisation serait l'intégration d'une base de données (ex: PostgreSQL) pour sauvegarder l'historique des prédictions et l'ajout d'un pipeline d'orchestration de données (comme Apache Airflow).
3. Déploiement Cloud : L'architecture Dockerisée est prête, la prochaine étape logique consisterait à déployer ces conteneurs sur des infrastructures managées publiques (AWS ECS ou Azure App Service) pour exposer l'outil aux utilisateurs finaux de l'entreprise.


17. Conclusion

L'objectif de ce projet certifiant était de transformer une masse de données brutes en un système intelligent de pilotage financier. En respectant une méthodologie Data Science rigoureuse, nous avons audité les données, redressé le déséquilibre inhérent au phénomène d'attrition, et mis en compétition plusieurs paradigmes algorithmiques (ML classique, ensembliste et Deep Learning).


Le choix final de la Régression Logistique (optimisée pour le Recall) démontre notre capacité à prioriser le retour sur investissement métier (ne pas rater de clients sur le départ) face à une simple course au score mathématique (le paradoxe de l'Accuracy de XGBoost). L'intégration de l'approche SHAP pour l'explicabilité, couplée au développement d'une architecture MLOps robuste (FastAPI et Docker), nous a permis de livrer un véritable outil opérationnel (Dashboard Streamlit). Ce projet valide notre capacité en tant que Data Engineers à concevoir, packager et justifier des solutions d'Intelligence Artificielle génératrices de valeur pour l'entreprise.










18. Annexes

Annexe 1 : Distribution de la Variable Cible (Churn)




Annexe 2 : Distributions avec la courbe de densité (KDE)







Annexe 3 : Analyse de la dispersion et détection des valeurs extrêmes (Outliers)




Annexe 4 : Taux de Churn selon le type de contrat




Annexe 5 : Impact des tickets support sur le Churn




Annexe 6 : Densité des frais mensuels selon le Churn




Annexe 7 : Matrice de corrélation des variables numériques




Annexe 8 : Comparaison des performances des 4 modèles (jeu de test)



Annexe 9 : Matrice de confusion XGBoost



Annexe 10 : Importance des variables (Valeurs SHAP), facteur d'attrition



Annexe 11 : Simulateur individuel

Navigation

Sélectionnez une interface :

- ☒ Simulateur Individuel
- ☐ Analyse Globale de la Base
- ☐ Performances des Modèles

Rôle Utilisateur : Customer Success Manager

Cet outil permet d'anticiper le Churn et d'arbitrer les budgets de rétention.

Simulateur de Risque d'Attrition Client

Saisissez les caractéristiques du client pour évaluer son niveau de risque et le manque à gagner associé.

Âge du client

18

42

100

Ancienneté (mois)

0

12

72

Échecs de paiement récents

0

0

5

Type de contrat

Month-to-month

Tickets Support ouverts ce mois

0

3

15

Score de Satisfaction Client (CSAT)

1

4

5

Facture Mensuelle (€)

65.00

Temps moyen de résolution (heures)

24.00

Méthode de paiement

Electronic check

Calculer le Risque d'Attrition

Annexe 12 : Analyse global de la base

Navigation

Sélectionnez une interface :

- ☐ Simulateur Individuel
- ☒ Analyse Globale de la Base
- ☐ Performances des Modèles

Rôle Utilisateur : Customer Success Manager

Cet outil permet d'anticiper le Churn et d'arbitrer les budgets de rétention.


Tableau de Bord Analytique de l'Attrition

Visualisation macroscopique des segmentations et des alertes de la base de données clients.


Répartition du Churn par Type de Contrat



Volume de Tickets Support vs Attrition



Analyse de la Sensibilité au Prix (Densité de Facturation)



Annexe 13 : Performances des modèles

Navigation

Sélectionnez une interface :

- ☐ Simulateur Individuel
- ☐ Analyse Globale de la Base
- ☒ Performances des Modèles

Rôle Utilisateur : Customer Success Manager

Cet outil permet d'anticiper le Churn et d'arbitrer les budgets de rétention.

Comparaison Académique et Validation des Modèles

Synthèse des résultats obtenus lors de la phase de modélisation supervisée.

	Modèle	Accuracy	Recall (Churn)	F1-Score (Macro)	ROC-AUC
0	Régression Logistique	0.668500	0.637200	0.533100	0.714300
1	Random Forest	0.883500	0.093100	0.538800	0.773900
2	XGBoost	0.890000	0.034300	0.500700	0.789800
3	Deep Learning (MLP)	0.832500	0.166600	0.537800	0.652900

Note d'Arbitrage Technique pour le Jury

Le Paradoxe de l'Accuracy : Bien que *XGBoost* et *Random Forest* affichent des précisions globales proches de 89%, ils souffrent d'un Rappel (Recall) critique (inférieur à 10%). Ils échouent à détecter la classe minoritaire en production.

Décision Métier : La **Régression Logistique** a été retenue pour l'intégration finale. Avec un Rappel de 63.7%, c'est le seul modèle capable d'intercepter efficacement deux tiers des clients sur le départ, maximisant ainsi le retour sur investissement du plan de rétention.

Annexe 14 : Test API Read Root

GET / Read Root

Parameters

Cancel

No parameters

Execute

Clear

Responses

Curl

```
curl -X 'GET' \
'http://localhost:8000/' \
-H 'accept: application/json'
```

Request URL

```
http://localhost:8000/
```

Server response

Code	Details
200	Response body <pre>{ "message": "Bienvenue sur l'API de prédiction de Churn. Utilisez /docs pour voir le Swagger." }</pre> Download Response headers <pre>content-length: 95 content-type: application/json date: Mon,22 Jun 2026 08:07:16 GMT server: uvicorn</pre>

Responses

Code	Description	Links
200	Successful Response Media type application/json Controls Accept header. Example Value Schema <pre>"string"</pre>	No links

Annexe 15 : Test API Health Check

GET

/health Health Check

Route pour vérifier que l'API est en ligne (Health Check).

Parameters

Cancel

No parameters

Execute

Clear

Responses

Curl

```
curl -X 'GET' \
'http://localhost:8000/health' \
-H 'accept: application/json'
```

Request URL

```
http://localhost:8000/health
```

Server response

Code	Details
200	Response body <pre>{ "status": "ok", "model_loaded": true }</pre> Download Response headers <pre>content-length: 35 content-type: application/json date: Mon, 22 Jun 2026 08:10:47 GMT server: uvicorn</pre>

Responses

Code	Description	Links
200	Successful Response Media type application/json Controls Accept header. Example Value Schema <pre>"string"</pre>	

 No links |

Annexe 16 : Test API Predict Churn

POST /predict Predict Churn

Reçoit les données du client, applique le preprocessing et retourne la probabilité de churn.

Parameters Cancel

No parameters

Request body required application/json

Edit Value | Schema

```
{
  "age": 0,
  "contract_type": "string",
  "monthly_fee": 0,
  "tenure_months": 0,
  "support_tickets": 0,
  "avg_resolution_time": 0,
  "payment_failures": 0,
  "csat_score": 0,
  "payment_method": "string"
}
```

Execute **Clear**

Responses

Curl

```
curl -X 'POST' \
  'http://localhost:8000/predict' \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "age": 0,
    "contract_type": "string",
    "monthly_fee": 0,
    "tenure_months": 0,
    "support_tickets": 0,
    "avg_resolution_time": 0,
    "payment_failures": 0,
    "csat_score": 0,
    "payment_method": "string"
  }'
```

Request URL

```
http://localhost:8000/predict
```

Server response

Code Details

200

Response body

```
{
  "prediction": 1,
  "probability": 0.9989718533166585,
  "status": "success"
}
```



Download

Response headers

```
content-length: 68
content-type: application/json
date: Mon, 22 Jun 2026 08:11:57 GMT
server: uvicorn
```

Responses

Code	Description	Links
200	Successful Response Media type application/json ▾ Controls Accept header. Example Value Schema "string"	No links
422	Validation Error Media type application/json ▾ Example Value Schema { "detail": [{ "loc": ["string", 0], "msg": "string", "type": "string" }] }	No links

Annexe 17 : Pipeline IA et architecture global

